

Universidade Tecnológica Federal do Paraná – UTFPR – Campus Curitiba
Departamento Acadêmico de Eletrônica – DAELN
Curso de Engenharia Eletrônica
Disciplina: IF69D e OPEET014 — Processamento Digital de Imagens
Semestre: 2026.1
Prof: Gustavo B. Borba e Humberto Gamba

RELATÓRIO

Segmentação de vasos em imagens de Doppler colorido: Distância Euclidiana vs. K-means

Alunos:

Etore Maloso Tronconi / 2235293

Henrique Gomes Pinto Bubniak / 2355876

jun.2026

1 Objetivo

Segmentar o vaso sanguíneo cujo fluxo se afasta da sonda (codificado em azul) **a partir da imagem de Doppler colorido**, isto é, tratando o problema como se apenas a figura exibida na tela do equipamento estivesse disponível. O trabalho compara, de forma padronizada, dois métodos de segmentação por cor implementados em MATLAB: limiarização da **distância Euclidiana** a uma cor de referência e agrupamento por **K-means** no espaço RGB, e avalia quantitativamente a segmentação de cada um contra um *ground truth*.

2 Fundamentação Teórica

2.1 Imagem de Doppler colorido

Neste trabalho, simulações de ultrassom Doppler foram realizadas com a *toolbox* MUST sobre *phantoms* sintéticos de vasos em imagens de resolução 128×128 pixels, cujos mapas de velocidade são armazenados nos arquivos `vd_signals_XX.mat`. A partir desses mapas, imagens coloridas são geradas pela renderização com o *colormap* `dopplermat` da *toolbox* MUST, que codifica a direção do fluxo em cor: tons de **azul/ciano** representam o fluxo que se *afasta* da sonda (velocidade negativa, o alvo deste trabalho), tons de **vermelho/amarelo** representam o fluxo que se *aproxima* (velocidade positiva), e o **preto** indica regiões de velocidade nula. Um conjunto de 15 simulações foi gerado com *ground truth* produzido a partir dos *phantoms* de vasos compostos por regiões azuis e vermelhas sobre fundo escuro, e a tarefa de segmentação consiste em isolar o vaso de fluxo negativo (azul/ciano), reduzindo-se, portanto, a um problema de segmentação por cor.. A convenção usual (e adotada pelo *colormap* `dopplermat` da *toolbox* MUST) associa tons de **azul/ciano** ao fluxo que se *afasta* da sonda (velocidade negativa, o alvo deste trabalho), tons de **vermelho/amarelo** ao fluxo que se *aproxima* (velocidade positiva) e o **preto** às regiões de velocidade nula. Segmentar o vaso azul reduz-se, portanto, a um problema de segmentação por cor.

2.2 Distância Euclidiana e limiarização de Otsu

Dada uma cor de referência $\mu = (\mu_R, \mu_G, \mu_B)$ representativa do alvo, a similaridade de cada *pixel* $\mathbf{x}$ pode ser medida pela distância Euclidiana no espaço RGB, dada pela

equação 1:

$$D(\mathbf{x}) = \sqrt{\sum_{c \in \{R, G, B\}} (I_c(\mathbf{x}) - \mu_c)^2}. \quad (1)$$

Quanto menor $D(\mathbf{x})$, mais próximo o *pixel* está da cor-alvo. A separação entre vaso e fundo é feita por um limiar t obtido automaticamente pelo método de **Otsu**, que maximiza a variância interclasses do histograma. Classificam-se como vaso os *pixels* com $D(\mathbf{x}) < t$.

2.3 Agrupamento por K-means

Alternativamente, o K-means particiona as cores da imagem em K agrupamentos (*clusters*) minimizando a distância intra-*cluster*. Espera-se que, com $K = 3$, os agrupamentos correspondam às três regiões dominantes da imagem renderizada: fluxo azul, fluxo vermelho e fundo. O agrupamento correspondente ao vaso-alvo é então selecionado automaticamente como aquele de menor distância média à cor de referência.

2.4 Métricas de avaliação

A máscara obtida é comparada *pixel a pixel* com o *ground truth*, contabilizando verdadeiros positivos (TP), falsos positivos (FP) e falsos negativos (FN). A partir dessas contagens definem-se as métricas das equações 2 a 3:

$$\text{Dice} = \frac{2 \text{ TP}}{2 \text{ TP} + \text{FP} + \text{FN}}, \quad \text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}}, \quad (2)$$

$$\text{Precisão} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad \text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}. \quad (3)$$

O coeficiente Dice e a IoU medem a sobreposição global; a precisão penaliza falsos positivos (excesso de área segmentada) e o *recall* penaliza falsos negativos (vaso não detectado).

3 Implementação

Os dados provêm de 15 simulações de ultrassom Doppler (toolbox MUST) sobre *phantoms* de vasos de 128×128 *pixels*. A Figura 1 mostra um *phantom* e o *ground truth* correspondente, gerado em `make_ground_truth.m` convertendo os vasos azuis do *phantom* em branco e todo o restante (fundo e vaso vermelho) em preto.




Figura 1: (a) Phantom de entrada (vasos azul/vermelho sobre fundo preto). (b) Ground truth (vaso azul $\rightarrow$ branco; restante $\rightarrow$ preto).

Para isolar exclusivamente o passo de segmentação, ambos os métodos partem da **mesma imagem** e do **mesmo pré-processamento**, segundo o *pipeline* implementado em `segment_doppler.m`:

- **Recorte e renderização** (`doppler_to_rgb.m`): como o mapa de velocidade abrange o dobro da largura do *phantom*, recortam-se as colunas centrais (FOV do *phantom*); o mapa recortado é saturado em $[-m, m]$ e renderizado em uma imagem RGB 128×128 com o *colormap* `dopplermap`, reproduzindo a figura que apareceria na tela do equipamento.
- **Suavização Gaussiana**: filtragem com `imgaussfilt` ($\sigma = 1,6$) para reduzir o ruído de cor das simulações antes de segmentar.
- **Segmentação**: aplicação de um dos dois métodos sobre a imagem suavizada. A cor de referência μ é a *interquartile mean* dos canais de uma pequena amostra do azul-alvo (`sample.png`, Figura 2), o que a torna robusta a *outliers*. O limiar de Otsu é obtido com `graythresh` e o agrupamento com `imsegkmeans` ($K = 3$).
- **Avaliação** (`eval_methods.m`): cálculo das métricas (`dice`, `jaccard`) das duas máscaras contra o *ground truth* nas 15 simulações, com geração da tabela-resumo, dos painéis de erro e do gráfico de barras.



Figura 2: Amostra `sample.png` da cor-alvo, usada para estimar a cor de referência μ .

As funções nativas da *Image Processing Toolbox* utilizadas foram `graythresh`, `imsegkmeans`, `imgaussfilt`, `imresize`, `dice` e `jaccard`. Para reproduzir os resultados, executa-se na pasta do projeto `make_ground_truth` seguido de `eval_methods`.

4 Resultados e conclusões

As médias das métricas sobre as 15 simulações estão na Tabela 1 e na Figura 3. A **distância Euclidiana** apresentou o maior Dice médio (0,681 *vs.* 0,675), além de IoU e precisão superiores, vencendo o K-means em **10 das 15** simulações pelo critério de Dice. O K-means, por sua vez, obteve o maior *recall* (0,936 *vs.* 0,889).

Tabela 1: Médias das métricas por método sobre as 15 simulações. Em **negrito**, o melhor valor de cada métrica.

Método	Dice	IoU	Precisão	Recall
Distância Euclidiana	0,681	0,523	0,566	0,889
K-means	0,675	0,515	0,537	0,936

A diferença entre os métodos é pequena, mas o padrão é consistente: **recall alto e precisão baixa** em ambos. Os mapas de erro da Figura 4 explicam o comportamento: o núcleo do vaso é corretamente segmentado (verde, TP), mas há um anel de falsos positivos (vermelho, FP) em torno dele, correspondente à transição de cor suavizada na borda do




Figura 3: Métricas médias por método. Os dois métodos têm recall alto e precisão sensivelmente menor, indicando tendência à sobre-segmentação.

vaso. O K-means apresenta um anel mais espesso porque o *cluster* azul absorve essas transições e parte do excesso ao redor do vaso, o que reduz sua precisão (0,537 vs. 0,566) apesar do *recall* elevado. A distância Euclidiana, ao usar um limiar de Otsu mais restritivo, descarta parte dessa borda e fica mais próxima do *ground truth*. Em alguns casos, porém, essa mesma restrição faz a distância Euclidiana perder *pixels* internos do vaso, o que explica as 5 simulações em que o K-means a supera.




Figura 4: Comparação qualitativa (verde = acerto, vermelho = falso positivo, azul = falso negativo). (a) Simulação 14, em que a distância Euclidiana vence; ambos os métodos exibem o anel de falsos positivos na borda. (b) Simulação 03, um dos casos em que o K-means supera a distância Euclidiana.

De modo geral, ambos os métodos conseguem localizar o vaso-alvo, mas nenhum atinge uma sobreposição alta (IoU em torno de 0,52), justamente pela dificuldade em delimitar a borda difusa do fluxo. Como o trabalho não aplica pós-processamento morfológico,

a fronteira segmentada acompanha diretamente o gradiente de cor da imagem renderizada.

Como continuidade, sugerem-se: (i) **pós-processamento morfológico**: abertura/fechamento para remover o anel de falsos positivos e seleção do maior componente conexo como vaso, o que tende a elevar a precisão; (ii) a comparação dos **mesmos métodos em outros espaços de cor** (HSV, Lab), possivelmente mais robustos à transição de cor da borda; e (iii) o confronto com **métodos de aprendizado profundo** de segmentação, usando as próprias simulações como base de treino.